

DOI:10.13196/j.cims.2020.04.023

# 基于全局边缘排序的超启发算法在绿色物流选址—路径优化问题中的应用

王万良<sup>1</sup>, 朱文成<sup>1</sup>, 赵燕伟<sup>2</sup>

(1. 浙江工业大学 计算机科学与技术学院, 浙江 杭州 310023;

2. 浙江工业大学 机械工程学院, 浙江 杭州 310014)

**摘要:**为了解决目前物流选址—路径优化问题(LRP),提出一种以低碳排放量、配送中心选址规划和车辆路径规划为目标的双目标LRP模型。针对传统启发式算法在解决大规模LRP时的通用性差、效率低的缺点,设计出一种以选择函数法作为选择策略、以基于全局边缘排序的评价指标作为接受策略的超启发算法。通过求解基准测试实例,该算法在解决所提LRP模型时,能准确、高效、智能地设计出调度方案。与传统启发式算法以及性能良好的超启发算法在解的整体质量、单个解收敛效率等方面进行对比,验证了所提方法的可行性和有效性。

**关键词:**碳排放;物流配送;双目标优化;全局边缘排序;超启发算法

**中图分类号:**TP391.9 **文献标识码:**A

## Application of hyper-heuristic algorithm based on global margin ranking in environmental LRP

WANG Wanliang<sup>1</sup>, ZHU Wencheng<sup>1</sup>, ZHAO Yanwei<sup>2</sup>

(1. College of Computer Science and Technology, Zhejiang University of Technology, Hangzhou 310023, China;

2. College of Mechanical Engineering, Zhejiang University of Technology, Hangzhou 310014, China)

**Abstract:** To solve the Location-Routing Problem(LRP), a bi-objective LRP model with low carbon emissions, distribution center location planning and vehicle route planning was proposed. To solve the disadvantages of poor generality and low efficiency for traditional heuristic algorithms in solving large-scale LRP, a hyper-heuristic algorithm based on selection function method as the selection strategy and the evaluation index based on global margin ranking as the acceptance strategy was designed. By solving a benchmark test instance, the algorithm could accurately, efficiently, and intelligently design a scheduling scheme when solving the proposed LRP model. By comparing with the traditional heuristic algorithm and the well-performing hyper-heuristic algorithm, the overall quality of the solution and the convergence efficiency of single solution were compared, which verified the feasibility and effectiveness of the proposed method.

**Keywords:** carbon emission; logistics; bi-objective optimization; global margin ranking; hyper-heuristic algorithm

## 0 引言

随着社会经济飞速发展和居民生活水平的提高,全人类日益关注大气污染等一系列环境问题。为保护大气环境,改善空气质量,我国积极采取各种措施,并提出“十三五”期间单位GDP的二氧化碳排

放下降18%。因此,物流行业作为温室气体排放大户,理应响应国家“十三五”号召,节能减排、实施绿色物流。优化物流调度来减少二氧化碳排放量不仅是节能减排的措施,并为企业减少了成本,提升本身的行业竞争力。

物流调度的优化问题可以分为配送中心选择问

收稿日期:2018-07-04;修订日期:2019-03-27。Received 04 July 2018;accepted 27 Mar. 2019.

基金项目:国家自然科学基金资助项目(61572438)。**Foundation item:** Project supported by the National Natural Science Foundation, China (No. 61572438).

题,货物配送问题,车辆路径问题等。配送作为物流系统的核心功能,直接与客户相关联,配送功能完成质量的好坏直接影响客户对整个物流服务的满意程度。而车辆配送路线的合理优化作为配送的核心部分对整个物流运输速度、成本、效益影响至关重要<sup>[1]</sup>。Salhi 等<sup>[2]</sup>首先提出,在没有考虑路径优化的情况下解决定位问题可能会导致次优的解决方案。

物流选址—路径优化问题(Location Routing Problem, LRP)模型同时考虑选址和路径优化,多目标 LRP 模型还将选址及配送成本、配送时间、碳排放量等因素考虑进来。多目标 LRP 模型在实际应用中更具有价值,使用此模型求解得到的调度方案在各方面都更具竞争力。因此,学者们对多目标 LRP 模型进行了广泛的研究分析。Vahdani 等<sup>[3]</sup>研究了在地震后的救援行动中,救灾物资和物资的有效分配,其将总成本和旅行时间作为目标,提出多目标混合的多期和多商品数学模型。Nedjati 等<sup>[4]</sup>研究了带服务时间限制的多目标问题:配送中心补货以及客户在预定步行距离内移动的选址问题,提出一种新的双目标整数线性规划模型,该模型以总加权等待时间和总损失量最小化为目标。Asgari 等<sup>[5]</sup>提出了考虑各种类型废物和多种处理技术的废物定位、路线问题的多目标模型,该模型包括 3 个目标函数,最大限度地处理设施的需求性,最小化与问题相关的各种成本,并最终减少未处理材料运输的风险。Bozorgi-Amiri 等<sup>[6]</sup>提出一个多目标的动态随机规划模型,用于人道主义救援物流问题。该模型提出了 3 个目标:最小化受灾地区所有时期的最大短缺量、总旅行时间以及灾前和灾后费用总和。Wang 等<sup>[7]</sup>考虑配送中心的位置和可用交通网络中的车辆路线问题,构建了一个最小化旅行时间、总成本和最大化交货可靠性的非线性 LRP 模型。在最新研究的 LRP 问题中,考虑低碳问题时,学者们多是将低碳作为其中一个约束条件或者将其作为惩罚系数<sup>[8]</sup>加入系统成本的目标函数中,在优化过程中都会难以避免地对某一目标有偏好,或对不同目标进行了重要程度的设置。本文将碳排放量最小化作为第二个目标函数与系统成本共同构成双目标模型进行优化,优化过程中不会存在对目标值的任何偏好信息。

此外,目前国内外的研究中,使用启发式算法进行 LRP 模型求解居多。张春苗等<sup>[9]</sup>采用量子进化算法结合局部搜索算法对低碳定位—车辆路径问题数学模型进行求解。钱晓明<sup>[10]</sup>等提出一种混合模

拟退火算法,解决单相电能表集中检定后的配送需求问题。启发式算法被设计来解决特定模型,在求解其他模型时缺乏通用性。超启发算法能很好地解决这个问题,并在求解大规模 LRP 问题(更复杂,在可接受的执行时间内不能由传统方法解决的问题)时,该算法具有更快的速度,即使最终得到的结果是一个近似最优解而不是全局最优(这是由随机搜索的性质造成的)。

因此,本文创新性地使用超启发算法来求解绿色 LRP 模型,提出一种新的选择策略与接受策略组合;在解决传统 LRP 的基础上,考虑碳排放量的影响。通过提出算法对调度方案进行优化,并运用启发式规则,选择出最优调度路径,最终得到科学、合理的调度方案。

## 1 多目标问题与超启发算法框架

### 1.1 多目标优化问题

多目标优化问题又称为多标准优化问题<sup>[11]</sup>。不失一般性,一个具有  $n$  个决策变量,  $m$  个目标变量的多目标优化问题可表述为

$$\begin{aligned} \min y &= F(x) = (f_1(x), f_2(x), \dots, f_m(x))^T. \\ \text{s. t.} \quad &g_i(x) \leq 0, i = 1, 2, \dots, q; \\ &h_j(x) = 0, j = 1, 2, \dots, p. \end{aligned} \quad (1)$$

其中:  $x = (x_1, \dots, x_n) \in X \subset R^n$  为  $n$  维的决策矢量,  $X$  为  $n$  维的决策空间,  $y = (y_1, \dots, y_m) \in Y \subset R^m$  为  $m$  维的目标矢量,  $Y$  为  $m$  维的目标空间。目标函数  $F(x)$  定义了  $m$  个由决策空间向目标空间的映射函数;  $g_i(x) \leq 0 (i = 1, 2, \dots, q)$  定义了  $q$  个不等式约束;  $h_j(x) = 0 (j = 1, 2, \dots, p)$  定义了  $p$  个等式约束。在此基础上,给出以下几个重要的定义。

**定义 1 可行解。**对于  $x \in X$ , 如果  $x$  满足(1)中的约束条件  $g_i(x) \leq 0 (i = 1, 2, \dots, q)$  和  $h_j(x) = 0 (j = 1, 2, \dots, p)$ , 则称  $x$  为可行解。

**定义 2 可行解集。**由  $X$  中的所有的可行解组成的集合称为可行解集合, 记为  $X_f$ , 且  $X_f \subseteq X$ 。

**定义 3 Pareto 占优。**假设  $x_A, x_B \in X_f$  是式(1)所示多目标优化问题的两个解, 则称与  $x_B$  相比,  $x_A$  是 Pareto 占优的, 当且仅当

$$\forall i = 1, 2, \dots, m, f_i(x_A) \leq f_i(x_B) \wedge \exists j = 1, 2, \dots, m, f_j(x_A) < f_j(x_B), \quad (2)$$

记作  $x_A \succ x_B$ , 也称为  $x_A$  支配  $x_B$ 。

**定义 4 Pareto 最优解。**一个解  $x^* \in X_f$  被称为 Pareto 最优解(或非支配解), 当且仅当满足如下

条件:

$$\neg \exists x \in X_f: x \succ x^*. \quad (3)$$

**定义5** Pareto 最优解集。Pareto 最优解集是所有 Pareto 最优解的集合,定义如下:

$$P^* \triangleq \{x^* \mid \neg \exists x \in X_f: x \succ x^*\}. \quad (4)$$

**定义6** Pareto 前沿面。Pareto 最优解集  $P^*$  中所有的 Pareto 最优解对应的目标矢量组成的曲面称为 Pareto 前沿面  $PF^*$ :

$$PF^* \triangleq \{F(x^*) = (f_1(x), f_2(x), \dots, f_m(x))^T \mid x^* \in P^*\}. \quad (5)$$

## 1.2 超启发算法

**定义7** 超启发算法。一种选择或者产生启发式算法来解决计算搜索问题的搜索方法<sup>[12]</sup>(或学习机制)。

超启发算法是“一个独立于问题的算法框架,它提供了一套策略来开发启发式优化算法”<sup>[13]</sup>。超启发算法的特点就是,作为高层策略,它的搜索空间是由一组用来对解空间进行搜索的底层启发式算子组成。底层的启发式算子可以是(邻域)操作算子,如交叉、变异、本地搜索,或者就可以是启发式算法。典型的超启发算法在逻辑结构上由控制域和问题域两个部分组成,如图1所示。

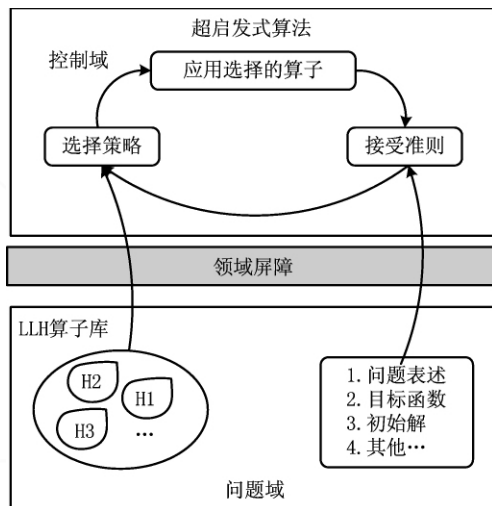


图1 超启发算法框架

问题域中包含由领域专家设计的问题描述、基本函数、评价函数以及若干低层启发式算法(Low-Level Heuristics, LLH);高层策略由超启发算法专家进行设计,包含了如何利用底层启发式算法构造可行解或者提升解质量的方法。问题域及控制域之间是领域屏蔽,需要定义两层结构之间进行信息传递的标准接口。

在最初提出的框架下,高层超启发式控制策略和底层启发式算子之间存在逻辑上的分离,使得基于组件的开发成为可能<sup>[14]</sup>。超启发式算法允许访问问题域的独立信息(如解的目标函数值),并进行一些记录(如记录每个底层算子的性能指标)。

考虑到启发式搜索空间的性质,超启发算法可以根据不同的标准用不同的方法进行分类。目前,有两种主要的超启发式算法:①启发式选择方法,在给定的时间内,选择底层启发式算法之一应用;②启发式生成方法,用给定的组件构成新的启发式算法。

## 2 绿色 LRP 问题描述及模型建立

在物流和运营问题的研究中,多数问题已经考虑到运输对环境的影响以及工业环境对运输活动成本的影响<sup>[15]</sup>。

### 2.1 问题描述

本文提出一个新的 LRP 数学模型,考虑燃料消耗最小化。该问题说明如下:

给定一组配送中心  $M$  和客户  $C$ ,目标是找到最佳的配送中心及其与客户点连接的路径。每个配送中心都有设置开放成本  $C_m$ 。在每两个客户点  $(i, j)$ ,  $i, j \in C$  之间运输有一个运输成本  $C_f$ 。每个客户  $i \in C$  都有一个需求  $d_i$ ,该需求只能由一辆车配送。有  $K$  辆容量为  $Q_K$  的车可供调用。每辆车在每两个客户点  $(i, j)$ ,  $i, j \in C$  之间运输有一个折旧成本  $C_d$ 。在传统的 LRP 模型中只考虑一个目标函数:最小化总运营成本,其中包括设施的设置成本,车辆折旧成本和两个客户点之间的运输成本。本文模型除了运营成本之外,还包括第二个目标函数,即考虑到由于运输中的油耗产生的碳排放量,将 LRP 作为一个双目标问题来进行优化。

### 2.2 符号与变量说明

$M\{m \mid m=1, \dots, M\}$  为一系列配送中心;

$C\{i \mid i=1, \dots, I\}$  为一系列客户点;

$V\{k \mid k=1, \dots, K\}$  为属于各个配送中心的车辆;

$K_m$  为属于配送中心  $m$  且同一车型的车辆;

$S\{M \cup C\}$  为配送中心和客户点的集合;

$d_i$  为客户  $i$  的需求;

$y_{ij}$  为离开客户点  $i$  后前往客户点  $j$  的车辆装载的货物总量;

$C_d$  表示单位车辆折旧成本;

$C_f$  表示单位燃油成本;

$C_m$  表示配送中心开放成本;

$D_{ij}$  表示客户  $i$  到客户  $j$  的距离;

$Q_k$  为车辆的容量;

$Q_m$  为配送中心的容量;

模型中的决策变量:

$$X_{ijk} = \begin{cases} 1, & \text{表示车辆 } k \text{ 从客户(配送中心)} i \\ & \text{到客户(配送中心)} j, \\ 0, & \text{否则;} \end{cases}$$

$$Z_m = \begin{cases} 1, & \text{表示配送中心 } m \text{ 开放;} \\ 0, & \text{否则。} \end{cases}$$

### 2.3 碳排放量计算

影响燃油消耗和二氧化碳排放量的因素很多,如装载率、行驶距离、行驶速度和地形坡度等。对以上所有因素进行定量分析是不现实的,必须进行适当的假设和简化。

二氧化碳排放量有不同的计算方法,根据 Kirby 等<sup>[16]</sup>的理论,二氧化碳排放量与燃油消耗量成正比例关系。本文采用文献<sup>[17]</sup>的方法三计算燃油消耗量和二氧化碳排放量:

$$F = G \times D \times (a \times L + b). \quad (6)$$

式中: $F$  为运输过程的燃油消耗量; $G$  为地形坡度因子; $D$  为车辆的行驶距离; $L$  为载货重量; $a, b$  为燃油消耗参数。二氧化碳排放量

$$E_{\text{co}_2} = F \times \eta. \quad (7)$$

式中: $E_{\text{co}_2}$  为二氧化碳排放量; $\eta$  为燃油转换系数。

由式(6)可知,影响二氧化碳排放量的因素有地形坡度、行驶距离和装载量 3 个。文献<sup>[18]</sup>证明地形坡度对于碳排放量并无明显影响,因此设式(6)中的  $G=1$ ,忽略地形坡度因素。

### 2.4 数学模型

双目标低碳 LRP 的数学模型如下:

$$\min C_m \sum_{m \in M} Z_m + C_d \sum_{i \in S} \sum_{j \in S} \sum_{k \in K_m} D_{ij} X_{ijk} + C_f G \sum_{i \in S} \sum_{j \in S} \sum_{k \in K_m} D_{ij} X_{ijk} [ay_{ij} + b]; \quad (8)$$

$$\min \eta G \sum_{i \in S} \sum_{j \in S} \sum_{k \in K_m} D_{ij} X_{ijk} [ay_{ij} + b]. \quad (9)$$

$$\text{s.t.} \quad \sum_{m \in M} \sum_{k \in K_m} X_{ijk} = 1, \forall i \in C; \quad (10)$$

$$\sum_{j \in C} X_{mjk} = 1, \forall m \in M, \forall k \in K_m; \quad (11)$$

$$\sum_{i \in C} X_{imk} = 1, \forall m \in M, \forall k \in K_m; \quad (12)$$

$$\sum_{m \in M} \sum_{j \in C} X_{mjk} \leq 1, \forall k \in V; \quad (13)$$

$$\sum_{m \in M} \sum_{j \in C} X_{mjk} + \sum_{n \in M} \sum_{j \in C} X_{jnk} \leq 1, \forall k \in V; \quad (14)$$

$$\sum_{i \in S} X_{ihk} - \sum_{j \in S} X_{hjk} = 0, \forall h \in C, k \in K_m; \quad (15)$$

$$\sum_{k \in K_m} \sum_{i \in C} d_i \sum_{j \in S} X_{ijk} \leq Q_m Z_m, \forall m \in M; \quad (16)$$

$$\sum_{i \in C} d_i \sum_{j \in S} X_{ijk} \leq Q_k, \forall k \in K_m; \quad (17)$$

$$\sum_{i \in S} y_{ij} - \sum_{m \in S} y_{jm} = d_j, \forall j \in C; \quad (18)$$

$$y_{ij} - (Q_k - d_i) X_{ijk} \leq 0, \forall i, j \in S, k \in K_m; \quad (19)$$

$$y_{ij} - X_{ijk} d_j \geq 0, \forall i, j \in S, k \in K_m; \quad (20)$$

$$\sum_{i \in S} \sum_{j \in S} X_{ijk} \leq |S| - 1, \forall k \in K_m; \quad (21)$$

$$X_{ijk} \in \{0, 1\}, \forall i, j \in S, k \in K_m; \quad (22)$$

$$Z_m \in \{0, 1\}, \forall m \in M. \quad (23)$$

其中:式(8)和式(9)为目标函数,其中第一部分为配送中心开放成本加汽车折旧成本加燃油成本,第二部分为二氧化碳排放量;式(10)保证每个客户均被访问一次;式(11)和式(12)表明车辆从配送中心出发,必须回到原配送中心;式(13)保证每一个运输车辆的路径最多从一个配送中心驶出;式(14)保证任何两个配送中心的车辆不会在同一条路径上;式(15)保证访问完客户后必须离开;式(16)保证每个配送中心访问的顾客总需求小于配送中心的容量;式(17)保证车的载重不大于它的载重能力;式(18)保证每辆车的载货量满足客户的需求量;式(19)和式(20)保证当  $X_{ijk} = 1$  时  $y_{ij} > 0$ , 否则  $y_{ij} = 0$ ;式(21)是子回路消除约束;式(22)和式(23)是对决策变量的描述。

### 3 基于全局边缘排序的超启发式算法

本章详细描述了所提出的基于全局边缘排序的超启发式算法(Hyper-Heuristic based on Global Margin Ranking, GMR\_HH)框架以及上层策略的细节。

#### 3.1 GMR\_HH 算法框架

算法 1 GMR\_HH。

1.  $h$ : 底层算子索引号;  $P_{in}$ : 输入种群;  $P_{new}$ : 新生成种群
2. 初始化种群;
3. while(满足终止条件停止迭代) do
4.  $h \leftarrow$  选择底层算子;
5.  $P_{new} \leftarrow$  执行底层算子( $h, P_{in}$ ); // 执行底层算子  $h$ , 对  $P_{in}$  进行操作产生新的种群  $P_{new}$
6. 更新种群;
7.  $P_{in} \leftarrow$  应用接受准则( $P_{in}, P_{new}$ ); // 全局边缘排序接受( $P_{in}$ ,

$P_{new}$ ) 集中最优解进入下次迭代

end

GMR\_HH 的算法框架如算法 1 所示。首先是初始化过程,包括产生初始解和建立选择式超启发算法的相关数据结构(步骤 2);在此过程之后,使用多个底层算子进行迭代,改进得到一组新解。每次迭代都会使用启发式选择方法选择一个底层启发式算子(Low-Level Heuristic, LLH)(步骤 4)并将选择的底层算子应用到(步骤 5)输入的解集合上( $P_{in}$ )来生成新的解集合( $P_{new}$ )。然后对与算法组件相关的一些数据/参数进行更新(步骤 6),并进行接收策略的工作(步骤 7),从由当前解和新生成解的组合构成的解集合中挑选出下次迭代的输入解集合。整个过程在进行固定迭代次数后终止,最后返回 Pareto 最优解集。

在初始化(步骤 2)和更新(步骤 6)过程中,启发式选择函数策略分别被用来进行初始化和在一组新解产生时对每个底层算子进行评分计算以此选择底层算子。

### 3.2 改进的选择函数选择策略

Maashi<sup>[19]</sup>等提出选择函数(Choice function, CF)启发式选择策略,为每一个底层启发式算子打分,用来指示其性能,并在每次迭代中选择分数最高的底层启发式算子进行操作。这种方法旨在平衡最优优化(选择最佳表现的底层启发式算子)和多样化(给予长时间未选择的启发式算子机会)。

本文使用以下指标对算子进行评分:空间覆盖大小<sup>[20]</sup>(SSC)、均匀分布<sup>[21]</sup>(UD)、非支配解比例<sup>[21]</sup>(RNI)。SSC 被定义为 Pareto 前沿面相对于参考点覆盖的空间大小,通常被用于评估多目标算法的收敛能力;UD 是 $[0,1]$ 中的一个值,用于度量 Pareto 前沿面上 Pareto 最优解集分布的均匀性,较高的 UD 值表示 Pareto 前沿面上的解分布更均匀;RNI 是 $[0,1]$ 中的一个值,是种群中非支配解占种群总数的百分比。针对本文算子,提出一个新的评价指标:优化率(OE):

$$OE = \frac{\sum_{i=1}^m \prod_{j=1}^n f_j(a_i) - \sum_{i=1}^m \prod_{j=1}^n f_j(b_i)}{\sum_{i=1}^m \prod_{j=1}^n f_j(a_i)} \quad (24)$$

式中(本文均以最小化目标函数为例): $m$  为种群大小; $n$  为目标函数个数; $f_j(x)$ ,  $j=1,2,\dots,n$  为第  $j$  个目标函数; $a_i$  ( $i=1,2,\dots,m$ ;  $a$  为上一代种群); $b_i$

( $i=1,2,\dots,m$ ;  $b$  为下一代种群)。通过所提方法,可以综合考虑所有目标函数的影响,并计算出经算子操作后,下一代种群优化效率。该方法需根据不同应用场景进行分析,如多目标值之间存在量级差距,需先进行归一化处理。

选择函数法首先使用上述指标:SSC, UD, RNI, OE 对所有底层算子根据得分进行排序,然后根据每个算子得到最好指标的频率选择算子。例如超启发框架中有 3 个底层算子: $h_1, h_2, h_3$ , 如果  $h_1$  在 SSC, UD, RNI 评价中得到最好的排名,  $h_2$  在 UD 和 RNI 中得分最高,但  $h_3$  只在 OE 中排名最高,则  $h_1, h_2, h_3$  得到最好指标的频率排名( $Freq_{rank}(h)$ )就是 1,2,3。

最终,某个算子  $h$  的得分可以用选择函数式(21)计算得到:

$$CF(h) = \alpha f_1(h) + f_2(h), \forall h \in H. \quad (25)$$

式中: $\alpha$  为正相关系数,  $H$  是底层算子的集合,  $h$  底层算子的索引号。 $(f_1)$  函数定义为:

$$f_1(h) = 2(N+1) - \{Freq_{rank}(h) + RNI_{rank}(h)\}. \quad (26)$$

式中  $N$  是所有底层算子的数量。假设  $h_1, h_2, h_3$  三个算子的  $RNI_{rank}(h) = \{1, 1, 3\}$ ; 且  $Freq_{rank}(h) = \{1, 2, 3\}$ , 就能得到  $f_1(h) = \{6, 5, 2\}$ 。 $f_2(h)$  是算子从上次被调用到现在的 CPU 时间(s)。每次迭代,  $CF(h)$  得分最高的算子被调用。

下面给出选择函数法步骤的具体说明:

Choice function.

Start

1. 初始化种群
2. 运行底层算子库中所有算子
3. 根据评价规则,对所有算子进行评价
4. 计算得到  $CF(h)$ , 选择  $CF(h)$  值最高的算子  $h$  作为初始算子
5. repeat
6. 执行选择的算子  $h$
7. 更新所有算子的评价
8. 更新所有算子的  $CF(h)$  值, 选择  $CF(h)$  值最高的算子
9. until(达到终止条件)

End

首先进行种群初始化(步骤 1), 然后运行底层算子库中所有的算子, 并根据评价规则, 对所有算子进行评价, 得到评价后计算出所有算子的  $CF(h)$  值, 并选择  $CF(h)$  值最高的算子  $h$  作为初始算子(步骤 2~步骤 4)。接下来是循环过程, 先执行选择的算子, 执行后根据本代数据更新所有算子的评价, 并根据评价值计算所有算子的  $CF(h)$  值, 选择  $CF$

( $h$ )值最高的算子作为下一代的执行算子,直到达成终止条件(步骤 5~步骤 9)。

### 3.3 基于全局边缘排序的接受准则

接受准则在超启发式中的重要地位,其决定了是否接受或拒绝由选定的底层算子产生的候选解决方案。Li 等<sup>[20]</sup>将 3 种选择策略:随机选择(Random Choice, RC)、固定顺序选择(Fixed Sequence, FS)、选择函数法(Choice Function, CF)与 3 种接受策略:全接受(All-Moves, AM)、大洪水接受(Great Deluge Acceptance, GDA)、最好值接受(Best Acceptance, BA)两两组合,进行实验。实验结果表明 RC-GDA 组合策略性能最优,因此本文将作为对比算法之一,用于与本文算法进行实验结果对比。目前有多种接受准则,但大多用于单目标优化。Maashi 等<sup>[22]</sup>改进了 GDA 策略,将其用于多目标优化。

现有的基于帕累托主导框架的多目标排序效率较低<sup>[23]</sup>,本文选取了一种基于排名的新型主导机制,称为全局边缘排序(Global Margin Ranking, GMR)。该机制针对基于 Pareto 排序的方法在处理大量弱优势关系(对支配其他个体数量相同的个体进行排序)时,排序性能急剧下降的问题,使用了目标函数值乘积的方法,为排序过程中存在的弱优势情况提供了解决方法,同时也能保障非支配解的排序比支配解更优。该机制在简化和加速优势关系评估的过程中,不仅考虑了整个种群所有个体的目标值信息,还使用了一种考虑群体中个体间距离的密度估计器,来保证种群个体具有更好的分布性。下面给出全局边缘排序的定义:

**定义 8** 全局边缘排序(GMR)。个体的 GMR 定义为个体的目标值与其他所有个体目标值差值的总和,定义如下:

$$GMR(X_i) \triangleq \sum_{X_j \neq X_i} \max((\prod_{m=1}^M f_m(X_i) - \prod_{m=1}^M f_m(X_j)), 0). \quad (27)$$

式中: $X_i, X_j$  是两个不同的解, $M$  是目标个数。结合 Pareto 占优的概念, $GMR(X_i)$  越小, $X_i$  支配的解越多。根据式(27),对任何两个解,当且仅当  $GMR(X_i) < GMR(X_j)$  时, $X_i$  相对于  $X_j$  在全局边缘排序中占优。如果  $GMR(X_i) = 0$ ,则  $X_i$  不会被解空间

中的任何其他个体 Pareto 支配。

**定义 9** 全局密度(Global Density, GD)。定义如下:

$$GD(X_i) = \sum_{j=1}^{pop} d_{i,j}, (i \neq j). \quad (28)$$

式中: $GD(X_i)$  表示  $X_i$  的全局密度; $d_{i,j}$  是  $[f_1(X_i), f_2(X_i), \dots, f_m(X_i)]$  与  $[f_1(X_j), f_2(X_j), \dots, f_m(X_j)]$  之间的欧式距离, $m$  为目标个数。 $GD(X_i)$  值越大, $X_i$  周围的个体越少,个体间的差异越大,分布性越好。

**定义 10** 全局综合排序(Global general ranking, GGR)。定义如下:

$$GGR(X_i) \triangleq \frac{GMR(X_i)}{GD(X_i)}. \quad (29)$$

式中  $GGR(X_i)$  表示  $X_i$  的全局综合排序。 $GGR(X_i)$  越小, $X_i$  越具优势,同时也表示  $X_i$  的 GD 值越小, $X_i$  具有更好的分布。

## 4 实验验证

为验证所建模型和提出算法的可行性与有效性,本文以 Barreto 基准测试实例中的算例([http://prodhonc.free.fr/Instances/instances\\_us.htm](http://prodhonc.free.fr/Instances/instances_us.htm))作为计算对象,使用 MATLAB R2016b 进行编程,在 Intel Core i5 处理器,4 G 内存,64 位 Windows 操作系统的计算机上进行实验。

模型中的参数描述及其取值在表 1 中给出。

表 1 相关参数表

| 参数符号   | 含义                        | 取值                     |
|--------|---------------------------|------------------------|
| $G$    | 地形坡度因子                    | 1                      |
| $a$    | 燃油消耗参数 1                  | $6.208 \times 10^{-3}$ |
| $b$    | 燃油消耗参数 2                  | 0.212 5                |
| $\eta$ | 燃油转换系数                    | 2.68                   |
| $C_m$  | 配送中心开放成本(元/个)             | 不定                     |
| $C_d$  | 单位车辆折旧成本(元/km)            | 1.28                   |
| $C_f$  | 单位燃油成本(元/L, 2018/6/11 油价) | 7.86                   |

### 4.1 实例验证

本节实验中选取了 Barreto 基准测试实例中的‘Christ100×10’测试场景(其中有 100 个客户点, 10 个配送中心)进行实验,并对结果的特征进行分析。

表2 Christ100×10 实例的计算结果

| 配送中心数量 | $f_1$ /元 | $f_2$ /kg | 配送中心成本/元 | 运输成本/元  | 燃油成本/元   |
|--------|----------|-----------|----------|---------|----------|
| 5      | 18 367   | 7 018.1   | 200      | 3 309.8 | 14 856.8 |
| 4      | 18 403   | 6 910.0   | 160      | 3 390.9 | 14 851.6 |
| 6      | 18 693   | 6 905.4   | 240      | 3 534.5 | 14 918.6 |
| 5      | 18 837   | 6 905.4   | 200      | 3 544.5 | 15 092.6 |
| 5      | 18 907   | 6 845.0   | 200      | 3 634.3 | 14 992.7 |
| 6      | 18 978   | 6 840.3   | 240      | 3 655.0 | 15 082.6 |
| 7      | 19 023   | 6 749.3   | 280      | 3 612.8 | 15 209.7 |




表2中给出了 Christ100×10 实例的 Pareto 前沿面以及 Pareto 最优解的细节描述。将对该实例的3种解决方案进行分析:①对应于目标函数  $f_1$  值(总成本)最小的解;②对应于目标函数  $f_2$  值(碳排放量)最小的解;③符合最大—最小准则的解,这个解通常是 Pareto 前沿面的中间点。

从表中可以很直观地看出,随着配送中心数量的增加,配送中心的开放成本增加,相应的总成本也会增加,即( $n=5, f_1=18\ 367$ )→( $n=7, f_1=19\ 023$ )。但是,随着配送中心数量的增加,碳排放量会相应的降低,这是因为配送中心增多,运送车辆需要行驶的距离会随之变短,这就会直接促成碳排放量的降低,即( $n=5, f_2=7\ 018.1$ )→( $n=7, f_2=6\ 749.3$ )。

从表中可以看出,还有两种较为特殊的情况,当配送中心数量都为5的时候,两个解的目标函数值分别为( $f_1=18\ 367, f_2=7\ 018.1$ )和( $f_1=18\ 907, f_2=6\ 845.0$ ),虽然成本相差无几,但碳排放量却后者更少,这是因为两种调度方案选择的路径不同,道路的地形坡度因子不同,导致碳排放量的区别;第二种当配送中心数量不同,一个开放4个中心,另一5个中心时,两个解的目标函数值分别为( $f_1=18\ 367, f_2=7\ 018.1$ )和( $f_1=18\ 403, f_2=6\ 910.0$ )与前一种情况类似。

#### 4.2 对比分析

本文选取 NSGA-II、SPEA2 以及使用 RC-GDA 策略的超启发算法与所提 GMR-HH 超启发算法(本文提出的超启发算法使用 CF-GMR 策略,

因此下列实验结果中使用 CF-GMR 代表 GMR-HH 算法)进行优劣对比。其中 NSGA-II 与 SPEA2 为多目标优化算法中经典的算法之一,RC-GDA 为文献[20]中所证明性能最优的超启发算法策略。

因为 NSGA-II、SPEA2 这两种传统启发式算法与超启发算法框架不同,算子无法统一,所以为了公平性只能保证种群大小、迭代次数、交叉变异率一致。对于 RC-GDA 算法,与 CF-GMR 同为超启发算法,为了公平性,只需进行策略的比较,算子与本文所用相同,其余设置均与传统算法设置相同。

实验参数的具体设置如表3所示。

表3 算法参数设置

| 参数名称 | 参数值  |
|------|------|
| 种群大小 | 100  |
| 迭代次数 | 80   |
| 交叉概率 | 0.85 |
| 变异概率 | 0.05 |

本节选用 Christ100×10 测试实例,分别使用 CF-GMR、NSGA-II、SPEA2、RC-GDA 算法进行计算,得出调度方案,并对4种调度方案进行对比分析。

从图2和图3可以看出,使用超启发算法得出的 Pareto 前沿面完全支配 NSGA-II、SPEA2 计算得到的 Pareto 面。这说明,使用 CF-GMR 算法计算得到的调度方案,在总成本与碳排放量这两个目标上,均少于其他两个算法得到的调度方案。这是因为,传统的多目标算法使用非支配排序,这在解决大规模的 LRP(复杂的 NP-Hard 问题)时存在效率

低下的问题<sup>[23]</sup>,通过对比,证明超启发算法在解决大规模 LRP 上具有明显优势。图 4 中,与性能较为优异的超启发策略进行对比,虽然在总成本上优势并不明显,但是在碳排放这个目标上,CF-GMR 所得的调度方案均是优于 RC-GDA。说明所提策略相较于对比算法,有一定的优势。




图2 CF-GMR与NSGA II Pareto前沿面对比图

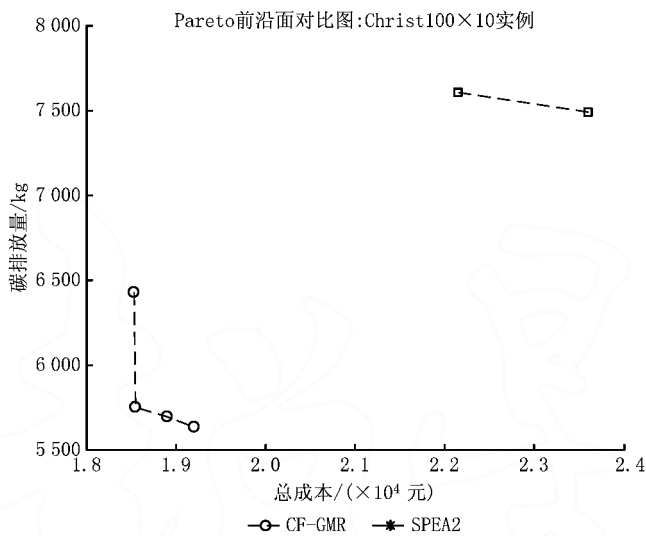


图3 CF-GMR与SPEA2 Pareto前沿面对比图

本节还通过单目标值随迭代次数的变化,对比分析在双目标优化的迭代过程中,单目标的收敛情况。图 5 反映了 CF-GMR 与 NSGA II 对比情况,从左图可以看出,在总成本这个目标的迭代过程中,NSGA II 的优化效果差,从 0 代到 80 代只从  $2.7 \times 10^4$  (元)降低到  $2.53 \times 10^4$  (元),但是本文算法可以从  $2.58 \times 10^4$  (元)降低到  $1.86 \times 10^4$  (元),优化效果明显。在右图中,虽然 NSGA II 在 30 代到 50 代之





图4 CF-GMR与RC-GDA Pareto前沿面对比图

间优于 CF-GMR,但是却在 38 代提前收敛,陷入局部最优,最终 CF-GMR 在碳排放量这个目标上的优化效果依旧优于 NSGA II。图 6 左图中,在 0 代到 40 代之间,SPEA2 的总成本明显低于 CF-GMR,这是由随机搜索的性质造成的,在初始化时,随机生成种群个体,得到的总成本低。但是 40 代之后,可以明显得出,CF-GMR 的收敛效率高,不会陷入局部最优,右图类似。在图 7 中,是两种超启发算法策略组合的对比,总成本效率近乎相同,且都优于传统的启发式算法,可以证明超启发算法在求解大规模 LRP 模型时,效率、解的质量均是优于传统算法的。在碳排放量的迭代过程中,RC-GDA 在 40 代时陷入局部最优,而 CF-GMR 能继续收敛。证明 CF-GMR 算法相较于 RC-GDA,在迭代两个目标的优化过程中都是具有优势的。








图5 CF-GMR与NSGA II总成本与碳排放量迭代对比图

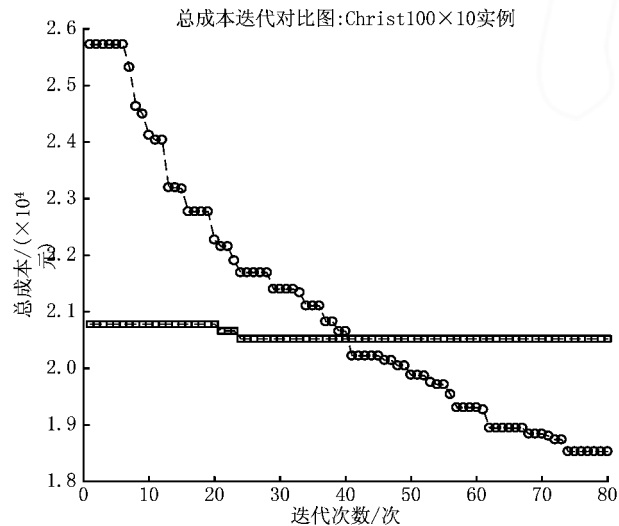


图6 CF-GMR与SPEA2总成本与碳排放量迭代对比图





图7 CF-GMR与RC-GDA总成本与碳排放量迭代对比图

## 5 结束语

本文通过对低碳LRP多目标优化问题进行研究,综合考虑配送中心开放、运输、燃油等成本以及碳排放量等目标,通过建立双目标模型,以总成本最小、碳排放量最少为目标,通过CF-GMR超启发算法,对配送中心选址以及物流配送调度方案进行优化,计算出最优调度方案。利用Barreto基准测试实例中名为Christ100×10的测试场景进行验证,与NSGA II、SPEA2和RC-GDA等算法从Pareto前沿面、总成本和碳排放的收敛情况等方面进行对比,优化结果和对比分析证明了调度方案的有效性。

与可行性。

LRP一直是物流领域研究的热点,在本文的研究内容之外,还有其他方面值得进一步探索和改进。例如带时间窗的LRP(Location-Routing Problem with Time Windows, LRPTW),对于带配送时间限制的问题来说,如果严格按照客户设定的服务时间为其服务,可能造成企业的配送成本增加;如果允许在某些客户点适当地延误,可能使运输成本大为减少,但该延误现象会造成客户满意度下降,决策者需对客户满意度和成本二者进行权衡。此外结合本文,考虑配送时间对碳排放量的影响值得继续研究。又例如动态LRP,动态LRP是LRP一个非常重要的领域,这在目前的文献中暂未有明确的解决途径。相比于配送中心的选址决策,将货物运输到具有不同需求的客户时的路径决策改变更频繁<sup>[24]</sup>,这就导致传统LRP模型不能很好地协调选址与路径的规划。因此,构建动态LRP模型作为能解决上述问题的重要方法之一,也是后续研究的一个重点。同时,超启发算法在LRP上得到很好的应用,以及对于超启发算法策略的改进,也值得继续研究。

#### 参考文献:

- [1] ZHAO Yanwei, ZHANG Jinglin, WANG Wanliang. Vehicle routing optimization method for logistics distribution[M]. Beijing: Science Press, 2014 (in Chinese). [赵燕伟, 张景玲, 王万良. 物流配送的车辆路径优化方法[M]. 北京: 科学出版社, 2014.]
- [2] SALHI, RAND J K, et al. The effect of ignoring routes when locating depots[J]. European Journal of Operational Research, 1989, 39(2): 150-156.
- [3] VAHDANI B, VEYSMORADI D, NOORI F, et al. Two-stage multi-objective location-routing-inventory model for humanitarian logistics network design under uncertainty[J]. International Journal of Disaster Risk Reduction, 2017, 27: 290-306.
- [4] NEDJATI A, IZBIRAK G, ARKAT J. Bi-objective covering tour location routing problem with replenishment at intermediate depots: Formulation and Meta-heuristics[J]. Computers & Industrial Engineering, 2017, 110: 191-206.
- [5] ASGARIN, RAJABI M, JAMSHIDI M, et al. A memetic algorithm for a multi-objective obnoxious waste location-routing problem: a case study[J]. Annals of Operations Research, 2017, 250(2): 1-30.
- [6] BOZORGI-AMIRIA, KHORSI M. A dynamic multi-objective location-routing model for relief logistic planning under uncertainty on demand, travel time, and cost parameters[J]. International Journal of Advanced Manufacturing Technology, 2016, 85(5/6/7/8): 1633-1648.
- [7] WANG H, DU L, MA S. Multi-objective open location-routing model with split delivery for optimized relief distribution in post-earthquake[J]. Transportation Research Part E, 2014, 69(3): 160-179.
- [8] XU Maozeng, YU Guoyin, ZHOU Xiang, et al. Low-carbon vehicle scheduling problem and algorithm with minimum-comprehensive-cost[J]. Computer Integrated Manufacturing Systems, 2015, 21(7): 1906-1914 (in Chinese). [许茂增, 余国印, 周翔, 等. 综合成本最小的低碳车辆调度问题及算法[J]. 计算机集成制造系统, 2015, 21(7): 1906-1914.]
- [9] ZHANG Chunmiao, ZHAO Yanwei, ZHANG Jingling et al. Location and routing problem with minimizing carbon[J]. Computer Integrated Manufacturing Systems, 2017, 23(12): 2768-2777 (in Chinese). [张春苗, 赵燕伟, 张景玲, 等. 低碳定位——车辆路径问题[J]. 计算机集成制造系统, 2017, 23(12): 2768-2777.]
- [10] QIAN Xiaoming, SUN Ying, LIU Jian. Solving watt-hour meter distribution vehicle routing problem based on hybrid simulated annealing algorithm[J]. Computer Integrated Manufacturing Systems, 2017, 23(11): 2553-2560 (in Chinese). [钱晓明, 孙颖, 刘建. 基于混合模拟退火算法求解电表配送车辆路径问题[J]. 计算机集成制造系统, 2017, 23(11): 2553-2560.]
- [11] GONG Maogu, JIAO Lichen, YANG Dongdong, et al. Research on evolutionary multi-objective optimization algorithms[J]. Journal of Software, 2009, 20(2): 271-289 (in Chinese). [公茂果, 焦李成, 杨咚咚, 等. 进化多目标优化算法研究[J]. 软件学报, 2009, 20(2): 271-289.]
- [12] BURKE E K, GENDREAU M, HYDE M, et al. Hyperheuristics: a survey of the state of the art[J]. Journal of the Operational Research Society, 2013, 64(12): 1695-1724.
- [13] SÖRENSEN K, GLOVER F W. Metaheuristics[M]. New York, N. Y., USA: Springer US, 2013.
- [14] COWLING P, KENDALL G, SOUBEIGA E. A hyperheuristic approach to scheduling a sales summit[C]//Proceedings of Practice and Theory of Automated Timetabling III. Berlin, Germany: Springer-Verlag, 2001.
- [15] BALDACCIO R, HADJICONSTANTINO E, MINGOZZI A. An exact algorithm for the vehicle routing problem based on a two-commodity network flow formulation[J]. Operations Research, 2004, 52(5): 723-738.
- [16] KIRBY H R, HUTTON B, MCQUAID R W, et al. Modeling the effects of transport policy levers on fuel efficiency and national fuel consumption[J]. Transportation Research Part D Transport & Environment, 2000, 5(4): 265-282.
- [17] SHI Chunyang. Research on low-carbon in the vehicle routing problem with simultaneous pickups and deliveries[D]. Beijing: Tsinghua University, 2011 (in Chinese). [史春阳. 同时取送货的车辆路径问题中的低碳研究[D]. 北京: 清华大学, 2011.]

- [18] SCOTT C, URQUHART N B, HART E. Influence of topology and payload on CO<sub>2</sub> optimised vehicle routing[M]. Applications of Evolutionary Computation. Berlin, Germany: Springer-Verlag, 2010.
- [19] MAASHI M, ÖZCAN E, KENDALL G. A multi-objective hyper-heuristic based on choice function[J]. Expert Systems with Applications, 2014, 41(9): 4475-4493.
- [20] LI W, ÖZCAN E, JOHN R. Multi-objective evolutionary algorithms and hyper-heuristics for wind farm layout optimisation[J]. Renewable Energy, 2017, 105: 473-482.
- [21] TAN K C, LEE T H, KHOR E F. Evolutionary algorithms for multi-objective optimization: performance assessments and comparisons[J]. Artificial Intelligence Review, 2002, 17(4): 251-290.
- [22] MAASHI M, KENDALL G. Choice function based hyper-heuristics for multi-objective optimization[J]. Applied Soft Computing Journal, 2015, 28(C): 312-326.
- [23] LI L, WANG W, XU X. Multi-objective particle swarm optimization based on global margin ranking[J]. Information Sciences, 2017, 375: 30-47.
- [24] ALBAREDA-SAMBOLAA M, NICKEL S. Multiperiod location-routing with decoupled time scales[J]. European Journal of Operational Research, 2012, 217(2): 248-258.

#### 作者简介:

王万良(1957—),男,江苏高邮人,教授,博士,博士生导师,研究方向:计算机智能自动化、智能调度等, E-mail: zjutwwl@zjut.edu.cn;

朱文成(1994—),男,江苏扬中人,硕士研究生,研究方向:多目标优化、超启发算法;

赵燕伟(1959—),女,河南郑州人,教授,博士生导师,研究方向:物流配送与优化调度、数字化产品现代设计。

